

Okkultes Wissen und Wissensorganisation

Vorlesung und Quellenübung

Sarah Lang*

2026

Vorlesung 'Okkultes Wissen und Wissensorganisation von Alchemie bis AI'

Quellenübung 'Okkultes Wissen und digitale Methoden'

*Max Planck Institute for the History of Science (Berlin)

Gastprofessur Digital Humanities, Bergische Universität Wuppertal

Datasheets for Datasets

Die mangelnde Ethik in den Digital Humanities

Mangelnde Ethik

- Berry 2022 weist auf eine geringe theoretische Auseinandersetzung mit Ethik in den DH hin.
- Auch im Machine Learning bestehen ähnliche Herausforderungen, die Forderungen nach Rechenschaftspflicht auslösen (Raji u. a. 2020)
- Algorithmus-Audits und Datensatzanalysen greifen diese Probleme auf, etwa bei der Überarbeitung von Datensätzen (z. B. ImageNet Cleanup, vgl. Yang u. a. 2020; Crawford 2021)

Bias und Lücken in historischen Datensätzen

- Historische Datensätze spiegeln Jahrhunderte gesellschaftlicher Ungleichheit wider. Strategien zum Umgang mit Bias in kolonialen Sammlungen sind nötig.
- Dies stärkt die Erklärbarkeit von KI durch Kontextualisierung der Daten.
- Fördert Diversität, Chancengleichheit und Inklusion in der Forschung.
- Ermöglicht präzise Analysen durch nachvollziehbare Datenprovenienz.

FAIR- und CARE-Prinzipien

- In den Digital Humanities breit anerkannt (Egan und Murphy 2022)
- **FAIR:** Findable, Accessible, Interoperable, Reusable.
- **CARE:** Collective Benefit, Authority to Control, Responsibility, Ethics (Global Indigenous Data Alliance 2021).

FAIR-Daten reichen nicht aus

- Trotz FAIR-Daten werden Datensätze selten nachgenutzt.
- Ein zentraler Grund ist unzureichende Dokumentation.
- FAIR bietet technische Leitlinien, aber wenig kritischen und kontextuellen Tiefgang.

Umfassendere Dokumentation

- Erforderlich für Erklärbarkeit, Reproduzierbarkeit und kritische Nutzung.
- Themen wie Data Gaps, Critical DH und Data/Code Studies benötigen reichhaltigere Metadaten.
- Projektbeschreibungen bieten oft nicht genügend Informationen für eine nachhaltige Nachnutzung.

Datasheets for Datasets: Eine Lösung?

Was sind Datasheets for Datasets?

- Vorgeschlagen von Gebru u. a. 2021 zur Dokumentation von Entstehung, Zweck und Bias eines Datensatzes.
- Ursprünglich für Machine Learning entwickelt, aber auch für die Digital Humanities geeignet.
- Ziel ist eine standardisierte Dokumentation für mehr Transparenz und Nachnutzung.

Warum ist das für die DH wichtig?

- Ansätze wie Data Feminism (Lang, Borek und Probst 2023) verstehen Dokumentation als Instrument der Rechenschaft.
- Macht sichtbar, wessen Interessen repräsentiert werden und wessen Stimmen fehlen.
- Ermöglicht eine kritische Auseinandersetzung mit Datensätzen über technische Beschreibungen hinaus.

Die kritische Wende in den DH

- Critical DH, Critical Data Studies und Critical Code Studies bieten Rahmenwerke zur kritischen Analyse von Daten.
- Die digitale Hermeneutik (Fickers, Tatarinov und Heijden 2022) überträgt geisteswissenschaftliche Kritik auf Daten, Algorithmen und den gesamten Technologie-Stack (Webb 2023).

Dokumentation als Antwort

- Adressiert koloniale Verzerrungen und Data Gaps (z. B. Gender Data Gap).
- Trägt zur Dekolonisierung des Fachs bei, indem strukturelle Bias sichtbar werden.
- Macht die Politik der Digitalisierung sichtbar (Zaagsma 2023), die durch Auswahlprozesse historische Machtstrukturen reproduziert und verstärkt.

Dokumentation als „niedere Arbeit“

- Viele Formen der Datenarbeit (Alvarado 2022), etwa Metadaten- und Dokumentationserstellung, gelten in den DH als hermeneutisch zentral, werden aber akademisch wenig anerkannt (Ross und Pilsch 2022).
- Fehlende Anreize verhindern den nötigen Einsatz von Zeit und Ressourcen.

Bedarf an institutioneller Unterstützung

- Dokumentation als legitime Forschungsleistung anerkennen.
- Eigene Förderlinien und Plattformen für Datensatzdokumentation schaffen.

Aktuelle Initiativen

- Data Papers (z. B. JOHD, ZfdG) dokumentieren Datensätze aus Sicht ihrer Ersteller:innen.
- *Reviews in DH* bewertet digitale Ressourcen, bleibt für echte Dokumentation jedoch zu knapp.

Die Rolle externer Infomediäre

- D'Ignazio und Klein 2020 schlagen unabhängige Datensatzbewertungen zur Stärkung der Rechenschaft vor.
- Externe Begutachtung könnte die Dokumentationsqualität verbessern.
- DH-Forschende wären gut geeignet, diese Rolle zu übernehmen.

Dokumentation als langfristige Investition

Konzeptionelle vs. technische Dokumentation

- Technische Dokumentation veraltet oft schnell.
- Konzeptionelle Dokumentation zu Aufbau, Zweck und Repräsentation ist langlebiger. Sie schafft langfristigen Mehrwert für Interpretation und Nachnutzung.

Datensatzdokumentation

- Ermöglicht Datensatzkritik und kritische Auseinandersetzung.
- Erleichtert die Analyse von Provenienz, Bias und Grenzen.
- Macht Begrenzungen historischer Daten zum Ausgangspunkt neuer Fragestellungen.

Dokumentation als grundlegende DH-Praxis

Zusammenfassend...

- Ethik in den DH bleibt untertheoretisiert – ähnlich wie Accountability im ML.
- FAIR-Daten reichen ohne umfassende Dokumentation nicht aus.
- Datasheets for Datasets bieten einen praktischen Rahmen zur Schließung dieser Lücken.
- Critical DH, Data Feminism und Transparenzinitiativen treffen in Dokumentationspraktiken zusammen.

Wir brauchen...

- Datensatzdokumentation als legitime Forschungsleistung.
- Institutionelle Anreize für Dokumentationsarbeit.
- Dokumentation, die technische, konzeptionelle und ethische Aspekte umfasst.

Praxis: Datensätze mit Datasheets beschreiben

Fallstudie: Analyse der digitalen Ressourcen

Überblick über hier diskutierte digitale Projekte oder Sammlungen

- Aktuelle Projekte
- Ältere Projekte
- Sehr unterschiedlicher Dokumentationsgrad
- Sehr unterschiedliche Projekttypen
- Breites Themenspektrum
- Alle zu einem größeren Thema im weiteren Sinne, doch sehr unterschiedlich

Typische Herausforderungen historischer Daten

- Überrepräsentation männlicher Eliten.
- Anders als bei modernen Datensätzen können wir die Daten nicht einfach neu erheben.
- Dokumentation ist notwendig, um Bias und Repräsentation zu analysieren.

Historischen Bias mit Datasheets analysieren

Datasheets als Werkzeug für kritische Analyse

- Wer ist im Datensatz repräsentiert? Wessen Stimmen fehlen?
- Welche Verzerrungen entstehen durch den Sammlungsprozess?
- Wie kann Transparenz die Nachnutzung verbessern?

Data Feminism anwenden

- Systemische Ungleichheiten in Datensätzen erkennen.
- Grenzen historischer Quellen verstehen.
- Datensätze fundiert interpretieren und nutzen.

Übung: Datasheets erstellen

Praktische Aufgabe

- Datensätze aus den digitalen Ressourcen auswählen.
- Dokumentationslücken und Bias analysieren.
- Datasheets zu Zweck, Grenzen und ethischen Fragen erstellen.

Erwartete Ergebnisse

- Praktische Erfahrung mit Datensatzdokumentation.
- Kritisches Verständnis historischer Datensätze entwickeln.
- Über Transparenz und Ethik von Daten reflektieren.

Los geht's!

Beispiele aus der Übung/VO (oder einen eigenen Datensatz mitbringen!)

Der Originalartikel *Datasheets for Datasets* mit allen 57 Fragen:

<https://dl.acm.org/doi/pdf/10.1145/3458723>

Warum wurde der Datensatz erstellt?

- Was war der Hauptzweck des Datensatzes?
- Sollte damit eine bestimmte Aufgabe oder Forschungslücke adressiert werden?

Wer hat den Datensatz erstellt?

- Welche Forschungsgruppe, Institution oder Organisation hat ihn entwickelt?
- Wer hat die Erstellung finanziert?

Was enthält der Datensatz?

- Was repräsentieren die Einträge? (z. B. Dokumente, Bilder, Personen, Orte)
- Wie viele Einträge gibt es? Vollständig oder Stichprobe?

Metadaten und Struktur

- Welche Datentypen sind enthalten – Rohdaten, Merkmale, Annotationen?
- Gibt es Labels oder Zielvariablen?
- Gibt es fehlende Werte? Falls ja, warum?
- Enthält der Datensatz Beziehungen zwischen Einträgen (z. B. Netzwerke)?

Wie wurden die Daten erhoben?

- Welche Verfahren wurden genutzt (z. B. Sensoren, manuelle Erfassung, APIs)?
- Wurde der Datensatz Stichproben-basiert erstellt? Falls ja, wie?
- Wer war an der Datenerhebung beteiligt und wie wurden diese Personen vergütet?

Ethische Aspekte

- Gab es eine Ethikprüfung (z. B. IRB)?
- Haben die Betroffenen der Datenerhebung zugestimmt? Falls ja, wie?
- Gab es eine Möglichkeit, die Zustimmung zurückzuziehen?

Vorverarbeitung und Bereinigung

- Wurden die Rohdaten verändert (z. B. Tokenisierung, Schwärzung)?
- Wie wurden fehlende Werte behandelt?
- Blieben die Rohdaten neben den verarbeiteten Daten erhalten?
- Ist die Vorverarbeitungssoftware für Reproduzierbarkeit verfügbar?

Wie wurde der Datensatz genutzt?

- Wurde der Datensatz bereits in Forschung oder Anwendungen eingesetzt?
- Gibt es ein Verzeichnis zugehöriger Publikationen und Projekte?
- Für welche weiteren Anwendungen wäre er geeignet?

Grenzen und Fehlanwendungen

- Gibt es bekannte Bias oder Einschränkungen?
- Für welche Anwendungen sollte der Datensatz **nicht** genutzt werden?

Der Artikel enthält viele weitere Fragen, u. a. zu Bereitstellung und Pflege von Datensätzen.

Literatur

- [1] Rafael C. Alvarado. „Datawork and the Future of Digital Humanities“. In: *The Bloomsbury Handbook to the Digital Humanities*. Hrsg. von James O’Sullivan. Bloomsbury Publishing, 2022, S. 361–372. DOI: [10.5040/9781350232143.ch-34](https://doi.org/10.5040/9781350232143.ch-34).
- [2] David M. Berry. „AI, Ethics, and Digital Humanities“. In: *The Bloomsbury Handbook to the Digital Humanities*. Hrsg. von James O’Sullivan. First. Bloomsbury Handbooks. London: Bloomsbury Academic, 2022, S. 445–458. DOI: [10.5040/9781350232143.ch-42](https://doi.org/10.5040/9781350232143.ch-42).
- [3] Kate Crawford. *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press, 2021.
- [4] Catherine D’Ignazio und Lauren Klein. *Data Feminism*. MIT Press, 2020. URL: <https://data-feminism.mitpress.mit.edu/>.
- [5] Patrick Egan und Órla Murphy. „Sharing as Care and Fair in the Digital Humanities“. In: *The Bloomsbury Handbook to the Digital Humanities*. Hrsg. von James O’Sullivan. First. Bloomsbury Handbooks. London: Bloomsbury Academic, 2022, S. 267–272. DOI: [10.5040/9781350232143.ch-25](https://doi.org/10.5040/9781350232143.ch-25).

- [6] Andreas Fickers, Juliane Tatarinov und Tim van der Heijden. „**Digital history and hermeneutics – between theory and practice: An introduction**“. In: *Digital History and Hermeneutics: Between Theory and Practice*. Hrsg. von Andreas Fickers und Juliane Tatarinov. Berlin, Boston: De Gruyter Oldenbourg, 2022, S. 1–20. DOI: [10.1515/9783110723991-001](https://doi.org/10.1515/9783110723991-001).
- [7] Timnit Gebru u. a. „**Datasheets for datasets**“. In: *Commun. ACM* 64.12 (Nov. 2021), S. 86–92. ISSN: 0001-0782. DOI: [10.1145/3458723](https://doi.org/10.1145/3458723). URL: <https://doi.org/10.1145/3458723>.
- [8] Global Indigenous Data Alliance. **CARE Principles of Indigenous Data Governance**. 2021. URL: <https://www.gida-global.org/care/>.
- [9] Sarah Lang, Luise Borek und Nora Probst. „**Data Feminism in DH**“. In: *DHd2023: Open Humanities Open Culture*. Konferenzabstracts. DHd2023: Open Humanities Open Culture. Trier: DHd, 2023, S. 19–22. DOI: [10.5281/zenodo.7715422](https://doi.org/10.5281/zenodo.7715422). URL: <https://doi.org/10.5281/zenodo.7715422>.
- [10] Inioluwa Deborah Raji u. a. „**Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing**“. In: *Conference on Fairness, Accountability, and Transparency (Fat* '20)*. New York, NY, USA: ACM, 2020, S. 12. DOI: [10.1145/3351095.3372873](https://doi.org/10.1145/3351095.3372873).

- [11] Shawna Ross und Andrew Pilsch. „**Labor, Alienation, and the Digital Humanities**“. In: *The Bloomsbury Handbook to the Digital Humanities*. Hrsg. von James O'Sullivan. First. Bloomsbury Handbooks. London: Bloomsbury Academic, 2022, S. 335–346. DOI: [10.5040/9781350232143.ch-32](https://doi.org/10.5040/9781350232143.ch-32).
- [12] Sharon Webb. **Defining Full Stack Feminism**. Full Stack Feminism. Juli 2023. URL: <https://doi.org/10.21428/6094d7d2.b65d448a>.
- [13] Kaiyu Yang u. a. „**Towards Fairer Datasets: Filtering and Balancing the Distribution of the People Subtree in the Imagenet Hierarchy**“. In: *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. 2020, S. 547–558.
- [14] Gerben Zaagsma. „**Digital History and the Politics of Digitization**“. In: *Digital Scholarship in the Humanities* 38.2 (2023), S. 830–851. DOI: [10.1093/llc/fqac050](https://doi.org/10.1093/llc/fqac050).