

Okkultes Wissen und Wissensorganisation

Vorlesung und Quellenübung

Sarah Lang*

2026

Vorlesung 'Okkultes Wissen und Wissensorganisation von Alchemie bis AI'

Quellenübung 'Okkultes Wissen und digitale Methoden'

*Max Planck Institute for the History of Science (Berlin)

Gastprofessur Digital Humanities, Bergische Universität Wuppertal

Einführung zu Large Language Models (LLMs)

Large Language Models: Grundidee


Was ist ein LLM?

Ein Large Language Model ist eine große mathematische Funktion, die für einen gegebenen Text vorhersagt, welches Wort oder Token als nächstes wahrscheinlich folgt.

Chatbot als wiederholte Vorhersage

Ein Chatbot erzeugt Antworten, indem das Modell wiederholt das nächste Token vorhersagt:

1. Der bisherige Dialog wird als Eingabe gegeben.
2. Das Modell berechnet Wahrscheinlichkeiten für mögliche nächste Tokens.
3. Ein Token wird ausgewählt.
4. Der neue Text wird wieder als Eingabe verwendet.



Nächstes Token als Fortsetzung eines Dialogs, 3Blue1Brown.


Nicht ein Wort, sondern eine Verteilung

Wahrscheinlichkeiten


Ein LLM sagt nicht einfach ein einzelnes Wort sicher voraus. Es erzeugt eine Wahrscheinlichkeitsverteilung über viele mögliche nächste Tokens.

- Sehr wahrscheinliche Tokens passen stark zum Kontext.
- Weniger wahrscheinliche Tokens können trotzdem ausgewählt werden.
- Dadurch wirken Antworten oft natürlicher und variieren bei gleicher Eingabe.

Das Modell selbst berechnet Wahrscheinlichkeiten aus Zahlenwerten. Die konkrete Antwort entsteht durch wiederholte Auswahl aus diesen Wahrscheinlichkeiten.



Wahrscheinlichkeitsverteilung für mögliche nächste Tokens, 3Blue1Brown.



Parameter: Die „Stellschrauben“ des Modells


Gewichte und Parameter

Das Verhalten eines Sprachmodells wird durch sehr viele Zahlenwerte bestimmt. Diese Werte heißen Parameter oder Gewichte.

- Zu Beginn sind die Parameter zufällig gesetzt.
- Das Modell produziert zunächst schlechte Vorhersagen.
- Durch Training werden die Parameter schrittweise verändert.
- Große Modelle können Milliarden oder Hunderte Milliarden Parameter besitzen.

Verbindung zu neuronalen Netzen

Wie beim Ziffernbeispiel bedeutet Lernen auch hier: Parameter so verändern, dass eine Fehlerfunktion kleiner wird.



Parameter als Stellschrauben eines großen Modells, 3Blue1Brown.

Vom Sprachmodell zum Chatbot

Warum Pre-Training nicht ausreicht

Ein Modell, das Internettexte fortsetzt, ist noch nicht automatisch ein hilfreicher Assistent. Chatbots benötigen zusätzliche Anpassung an Dialoge, Instruktionen und Nutzendererwartungen.

Reinforcement Learning with Human Feedback

Bei RLHF bewerten Menschen Antworten des Modells. Diese Rückmeldungen werden genutzt, um die Parameter weiter anzupassen.

- hilfreiche Antworten werden wahrscheinlicher
- problematische Antworten werden unwahrscheinlicher
- das Modell wird stärker auf Assistentenverhalten ausgerichtet



Transformer: Warum moderne LLMs funktionieren


Transformer

Seit 2017 bilden Transformer die Grundlage vieler moderner Sprachmodelle. Sie verarbeiten Text nicht einfach Wort für Wort, sondern können viele Beziehungen im Text parallel berechnen.

Attention

Die zentrale Operation heißt **Attention**. Sie erlaubt es Tokens, Informationen aus ihrem Kontext aufzunehmen.

- Ein Wort wie „Bank“ erhält je nach Kontext unterschiedliche Bedeutung.
- Der Kontext kann andere Wörter stärker oder schwächer gewichten.
- Dadurch werden Bedeutungen in Zahlenvektoren kontextabhängig angepasst.



Attention: Bedeutung durch Kontext, 3Blue1Brown.

Text als Zahlen: Tokens und Vektoren


Warum Zahlen?

Neuronale Netze können nicht direkt mit Wörtern arbeiten. Text muss zuerst in Zahlen umgewandelt werden.

Token-Vektoren

Jedes Token wird durch eine lange Liste von Zahlen repräsentiert. Diese Vektoren enthalten Informationen, die während des Trainings nützlich für Vorhersagen werden.

- Tokens können Wörter, Wortteile oder Zeichenfolgen sein.
- Vektoren verändern sich durch den Kontext.
- Am Ende wird aus dem letzten Kontextzustand die nächste Token-Verteilung berechnet.



Was man aus LLMs über ML lernen kann


Gemeinsame Grundidee

Auch LLMs sind neuronale Netze: Sie lernen aus Beispielen, indem sie Parameter verändern und Fehler bei Vorhersagen reduzieren.

- **Input:** bisheriger Text oder Dialog.
- **Output:** Wahrscheinlichkeiten für nächste Tokens.
- **Training:** Vergleich mit tatsächlicher Fortsetzung.
- **Parameter:** viele gelernte Gewichte.
- **Evaluation:** Qualität ist nicht nur technische Genauigkeit, sondern auch Nützlichkeit, Angemessenheit und Zuverlässigkeit.

'Stochastische Papageien'

LLMs wirken sprachlich kompetent, aber technisch beruhen sie auf statistischer Vorhersage und großskaliger Optimierung (Bender u. a. 2021).



Transformer: Die Technik hinter LLMs


GPT

GPT steht für **Generative Pre-Trained Transformer**.

- **Generative:** Das Modell erzeugt neuen Text.
- **Pre-Trained:** Es wurde auf großen Datenmengen vortrainiert.
- **Transformer:** Die Architektur verarbeitet Text über Tokens, Vektoren und Attention.

Grundidee

Ein Transformer erhält Text als Eingabe und erzeugt eine Wahrscheinlichkeitsverteilung über mögliche nächste Tokens.



GPT als Modell zur Vorhersage des nächsten Tokens, 3Blue1Brown.

Vom Text zu Tokens

Tokenisierung

Der Eingabetext wird zuerst in kleinere Einheiten zerlegt. Diese Einheiten heißen Tokens.


Beispiel

To date, the cleverest thinker of all time was ...

kann etwa zerlegt werden in:

*To | date | , | the | cle | ve |
rest | thinker | ...*

- Tokens können Wörter, Wortteile oder Satzzeichen sein.
- Das Modell arbeitet nicht direkt mit Text, sondern mit numerischen Repräsentationen dieser Tokens.




Zerlegung von Text in Tokens, 3Blue1Brown.

Embeddings: Tokens als Vektoren

Embedding Matrix

Die Embedding Matrix funktioniert wie eine Nachschlagetabelle:

- Jede Spalte oder Zeile gehört zu einem Token im Vokabular.
- Die Werte beginnen zufällig.
- Im Training werden sie so angepasst, dass sie nützliche Bedeutungsinformationen tragen.



Tokens werden über eine Embedding Matrix in Vektoren übersetzt, 3Blue1Brown.

Embedding

Jedes Token wird in einen Vektor übersetzt, also in eine lange Liste von Zahlen. Diese Vektoren bilden die Eingabe für den Transformer.

Bedeutung als Richtung im Vektorraum

Geometrische Intuition


Embeddings kann man sich als Punkte oder Richtungen in einem hochdimensionalen Raum vorstellen.

- Wörter mit ähnlicher Bedeutung liegen oft näher beieinander.
- Bestimmte Richtungen können semantische Unterschiede ausdrücken.
- Klassisches Beispiel:

$$\text{king} - \text{man} + \text{woman} \approx \text{queen}$$

Wichtig

Diese Struktur wird nicht manuell programmiert, sondern entsteht durch Training auf großen Textmengen.



The **King** doth wake tonight and takes his rouse ...



Bedeutungsrichtungen im Embedding-Raum, 3Blue1Brown.

Dot Product: Ähnlichkeit messen


Skalarprodukt

Das *Dot Product* zweier Vektoren misst, wie stark sie in eine ähnliche Richtung zeigen.

- Positiver Wert: ähnliche Richtung.
- Wert nahe 0: kaum Zusammenhang.
- Negativer Wert: entgegengesetzte Richtung.

Warum ist das relevant?

Transformer verwenden solche Ähnlichkeitsmessungen, um zu bestimmen, welche Tokens im Kontext füreinander wichtig sind.



Kontext: Vektoren verändern ihre Bedeutung


Mehr als einzelne Wörter

Ein Token-Vektor startet als Repräsentation eines einzelnen Tokens. Im Transformer wird er durch Kontext schrittweise verändert.

Beispiel

Das Wort *model* bedeutet in *machine learning model* etwas anderes als in *fashion model*. Der Kontext verändert die relevante Bedeutung.

- Attention erlaubt Tokens, Informationen aus anderen Tokens aufzunehmen.
- Dadurch entstehen kontextreichere Vektoren.
- Diese Vektoren dienen am Ende zur Vorhersage des nächsten Tokens.



Transformer-Blöcke: Attention und Feed-Forward


Attention Block

Im Attention Block kommunizieren Token-Vektoren miteinander. Das Modell entscheidet, welche Teile des Kontextes für welche Tokens wichtig sind.

Feed-Forward Layer

Danach verarbeitet ein Feed-Forward Layer jeden Vektor einzeln. Alle Vektoren durchlaufen dieselbe Operation parallel.

- Attention: Austausch zwischen Tokens.
- Feed-Forward: weitere Verarbeitung jedes Token-Vektors.
- Viele Wiederholungen dieser Blöcke machen das Modell tief.



Unembedding: Zurück zu möglichen Tokens

Letzter Schritt

Nach vielen Transformer-Blöcken enthält der letzte Vektor der Sequenz Informationen aus dem gesamten verfügbaren Kontext.


Unembedding Matrix

Eine Unembedding Matrix übersetzt diesen Vektor in eine Liste von Werten:

- ein Wert für jedes Token im Vokabular
- diese Werte heißen **Logits**
- sie sind noch keine Wahrscheinlichkeiten

Logits

Aus den Logits wird anschließend eine Wahrscheinlichkeitsverteilung für das nächste Token berechnet.



Softmax: Aus Logits werden Wahrscheinlichkeiten


Problem

Die Logits können beliebige Zahlen sein: negativ, sehr groß oder sehr klein. Für eine Vorhersage brauchen wir aber Wahrscheinlichkeiten.

Softmax

Softmax wandelt eine Liste beliebiger Zahlen in eine Wahrscheinlichkeitsverteilung um:

- alle Werte liegen zwischen 0 und 1
- alle Werte summieren sich zu 1
- größere Logits erhalten höhere Wahrscheinlichkeiten



Softmax erzeugt eine Verteilung über mögliche nächste Tokens. Platzhalter.

Temperatur: Wie zufällig ist die Ausgabe?


Sampling

Ein Modell kann aus der Softmax-Verteilung ein nächstes Token auswählen. Dabei muss nicht immer das wahrscheinlichste Token gewählt werden.

Temperatur

Die Temperatur verändert die Form der Wahrscheinlichkeitsverteilung.

- **Niedrige Temperatur:** wahrscheinlichste Tokens dominieren.
- **Hohe Temperatur:** auch weniger wahrscheinliche Tokens werden häufiger gewählt.
- **Temperatur 0:** nahezu deterministische Auswahl des wahrscheinlichsten Tokens.



Temperatur verändert die Sampling-Verteilung. Platzhalter.

Kritische Perspektiven auf LLMs und KI-Ethik

LLMs, KI-Ethik und die Geisteswissenschaften

Geisteswissenschaftler:innen, die Large Language Models (LLMs) nutzen, müssen sich mit ethischen Fragen auseinandersetzen, die über technische Leistungsfähigkeit und rechtliche Compliance hinausgehen.

Wir brauchen mehr

- Gängige KI-Ethik wird häufig durch rechtliche und technische Fragestellungen geprägt.
- Diese Ansätze priorisieren Compliance, Sicherheit und Erklärbarkeit.
- Historische und geisteswissenschaftliche Forschung wirft zusätzliche epistemische Fragen auf zu:
 - Provenienz,
 - Interpretation,
 - historischem Kontext,
 - Repräsentation,
 - Macht.

Grenzen gängiger KI-Ethik

Bestehende Rahmenwerke konzentrieren sich häufig auf:

- rechtliche Compliance,
- Datenschutz,
- Erklärbarkeit,
- Risikominimierung.

Was fehlt?

Geisteswissenschaftliche Perspektiven betonen:

- historischen Kontext,
- Wissensproduktion,
- Arbeit,
- Machtverhältnisse,
- Repräsentation,
- Epistemologie.

Ein ethischer Umgang mit KI in den Geisteswissenschaften erfordert mehr als regulatorische Compliance. Er verlangt eine kritische Reflexion darüber, wie Wissen erzeugt, strukturiert und reproduziert wird.

KI-Outputs erklären: explainable AI

Das Versprechen und die Grenzen erklärbarer KI

Warum Erklärbarkeit populär wurde

Explainable AI (XAI) soll:

- algorithmische Intransparenz verringern,
- ermöglichen Schuldige zur Rechenschaft zu ziehen,
- menschliche Kontrolle unterstützen.

Kritische Perspektive

Forschende aus der Kritischen Theorie, feministischen Technikforschung und den Digital Humanities argumentieren:

- Erklärungen beseitigen zugrunde liegende Verzerrungen nicht,
- Transparenz allein schafft keine Gerechtigkeit,
- technische Lösungen können strukturelle Probleme verdecken.

Risiko

Erklärbarkeit kann als „Pflasterlösung“ wirken, die den Eindruck von Verantwortlichkeit erzeugt, ohne die Ursachen anzugehen.

Erklärbarkeit als Diagnose statt Lösung

Neubewertung von Erklärbarkeit

Erklärbarkeit sollte dienen als:

- Diagnoseinstrument,
- Ausgangspunkt für Kritik,
- Mittel zur Aufdeckung struktureller Probleme,

statt als vollständige ethische Lösung.

Möglicher Nutzen von XAI

- Verborgene Verzerrungen sichtbar machen.
- Problematisches Modellverhalten aufdecken.
- Audits und Evaluation unterstützen.
- Bereiche mit Handlungsbedarf identifizieren.

Erklärbarkeit vs. strukturelle Kritik

Explainable AI (XAI)	Kritische GeWi Ansätze
Transparenz	Machtanalyse
Modellausgaben	Datenprovenienz
Technische Rechenschaftspflicht	Historischer Kontext
Post-hoc-Erklärungen	Strukturkritik
Compliance	Ethische Reflexion
Fokus auf Algorithmen	Fokus auf Daten, Arbeit & Infrastruktur

Fazit

Erklärbarkeit kann Probleme sichtbar machen, ihre Bewältigung erfordert jedoch breitere kritische Rahmenwerke, die die historischen, sozialen und epistemologischen Dimensionen von KI-Systemen berücksichtigen.

Von Erklärbarkeit zu kritischer Evaluation

Obwohl Explainable AI (XAI) strukturelle Probleme nicht allein lösen kann, bleibt sie ein wertvolles Diagnoseinstrument.

Mögliche Vorteile von XAI

- Verborgenes Modellverhalten sichtbar machen.
- Systematische Schwächen aufdecken.
- Algorithmus-Audits unterstützen.
- Diskrepanzen zwischen Ausgaben und zugrunde liegenden Mechanismen identifizieren.

Fazit

Erklärbarkeit ist am nützlichsten, wenn sie Teil einer umfassenderen kritischen Evaluation ist und nicht als eigenständige ethische Lösung verstanden wird.

Das Problem maschineller Selbsterklärungen

Das Beispiel Claude

Jüngere Forschung zeigt, dass Claude mathematische Probleme korrekt lösen kann, ohne tatsächlich den mathematischen Verfahren zu folgen, die das Modell zu verwenden behauptet.

Beobachtetes Verhalten

- Erzeugt lehrbuchartige Erklärungen.
- Generiert überzeugende Begründungsketten.
- Gelangt über statistische Next-Token-Vorhersage zu Antworten.
- Führt die beschriebenen Schlussfolgerungsschritte nicht notwendigerweise tatsächlich aus.

Implikation

KI-generierte Erklärungen können selbst Halluzinationen sein und werfen damit Zweifel an der Verlässlichkeit maschineller Selbsterklärungen auf.

Halluzinationen und wissenschaftliche Integrität

Halluzinationen gehören inzwischen zu den meistdiskutierten Risiken von LLMs.

Risiken für die Wissenschaft

- Erfundene Zitate.
- Erfundenen Fakten.
- Irreführende Zusammenfassungen.
- Plausible, aber falsche Informationen.

Folgen

- Geringere Forschungsqualität.
- Gefährdung wissenschaftlicher Integrität.
- Mögliche Verstärkung von Fehlinformationen.
- Höherer Aufwand für die Verifikation.

Open-Washing und Intransparenz von Datensätzen

Das (In-)Transparenzproblem

Viele KI-Systeme werden als offen beworben, obwohl die zu ihrem Training verwendeten Datensätze nicht zugänglich sind.

Was „Open-Washing“ verbirgt

- Unbekannte Trainingsdaten.
- Inhalte ohne Einwilligung.
- Raubkopiertes Material.
- Schädliche oder diskriminierende Daten.
- Begrenzte Rechenschaft

Folge

Nutzende können unbewusst Technologien nutzen, die auf ethisch problematischen Datensätzen und institutionellen Praktiken beruhen.

Ein fortbestehendes Problem

Problematische Datensätze bleiben oft lange einflussreich, selbst nachdem ihre Schwächen erkannt wurden.

Warum?

- Hohe Entwicklungskosten.
- Fehlende Alternativen.
- Etablierte Infrastrukturen.
- Fortgesetzte Wiederverwendung in verschiedenen Bereichen.

In älteren Datensätzen verankerte Verzerrungen prägen weiterhin neue KI-Systeme und wissenschaftliche Werkzeuge.

Generalisierung und der Verlust historischer Nuancen

Wie LLMs Wissen erzeugen

LLMs bevorzugen:

- dominante Narrative,
- Mehrheitspositionen,
- verallgemeinernde Zusammenfassungen,
- statistisch häufige Muster.

Warum das für Historiker:innen wichtig ist

Historiker:innen interessieren sich häufig für:

- Ausnahmen,
- marginalisierte Stimmen,
- kontextuelle Spezifik,
- historische Nuancen.

Die Architektur von LLMs bevorzugt systematisch Mainstream-Perspektiven gegenüber historisch marginalisierten Sichtweisen.

Das Datenproblem in der KI-Ethik

Von Modellen zu Daten

Die Aufmerksamkeit verlagert sich zunehmend vom Modellverhalten auf die Datensätze, die KI-Systeme prägen.

Zentrale Herausforderungen

Historische und kulturelle Datensätze enthalten häufig:

- unklare Provenienz,
- Archivverzerrungen,
- ungleiche Repräsentation,
- eingebettete Machtstrukturen,
- epistemische Intransparenz.

Das funktioniert aber leider nur begrenzt, weil die Daten ja nicht offen zugänglich sind...

Verschiedene ethische Strömungen

Ethische Fragen jenseits von Bias

Weitere Herausforderungen durch LLMs

- Halluzinierte Zitate und Fehlinformationen.
- Gefährdung wissenschaftlicher Integrität.
- Umweltkosten des Modelltrainings.
- Umverteilung und Entwertung von Arbeit.
- Abhängigkeit von intransparenten kommerziellen Infrastrukturen.

Beispiele

- Ghost Work und unsichtbare Arbeit.
- Materielle und ökologische Auswirkungen von KI.
- „Open-Washing“ und irreführende Transparenzversprechen.

KI-Ethik muss neben der technischen Leistungsfähigkeit auch soziale, ökologische und institutionelle Folgen berücksichtigen.

Kritische geisteswissenschaftliche Ansätze zur KI

Alternative Traditionen

Mehrere geisteswissenschaftlich geprägte Forschungsfelder bieten Werkzeuge zur Analyse von KI-Systemen:

- Critical Archival Studies.
- Critical Data Studies.
- Critical Digital Humanities.
- Feministische Technikforschung.
- Data Feminism.

Gemeinsamer Fokus

Diese Ansätze richten ihre Aufmerksamkeit auf:

- Macht,
- Arbeit,
- Repräsentation,
- Ausschluss,
- historischen Kontext.

Ziel

Der Fokus soll von technischer Optimierung auf die kritische Bewertung der Systeme und Infrastrukturen verschoben werden, die Wissen hervorbringen.

Drei Traditionen der KI-Ethik

Informatik

- Fokus auf technische Lösungen.
- Erklärbarkeit, Robustheit, Sicherheit.
- Rechenschaftspflicht nachkommen.

Philosophie

- Moralisches Denken.
- Maschinenethik.
- Normative Bewertung von KI-Systemen.

Kritische & feministische Ansätze

- Machtstrukturen.
- Intersektionalität.
- Aktivistische Forschung.
- Arbeit und soziale Gerechtigkeit.

Warum die GEWI andere ethische Rahmenwerke benötigen

Die geisteswissenschaftliche Perspektive

Forschende, die mit historischen Datensätzen arbeiten, befassen sich mit:

- Provenienz,
- Repräsentation,
- archivischen Leerstellen,
- Interpretation,
- historischen Verzerrungen.

Was bestehenden Rahmenwerken häufig fehlt

Rechtliche und compliance-orientierte Ansätze behandeln selten:

- verantwortungsvolle Interpretation,
- Fragen der Repräsentation,
- historische Komplexität,
- Kontextualisierung.

Geisteswissenschaftler:innen benötigen Orientierung für einen verantwortungsvollen Einsatz von KI, nicht nur zur Vermeidung rechtlicher Verstöße.

Unsichtbares sichtbar machen: Audits

Von der Erklärung zur Untersuchung

Auditbasierte Ansätze bieten eine Alternative zu einer rein technischen KI-Ethik.

Beispiele

- Datensatz-Audits.
- Metadaten-Audits.
- Modell-Audits.
- Kritische Archivanalyse.
- Methoden des Data Feminism.

Ziel

- Verborgene Annahmen aufdecken.
- Verzerrungen und Ausschlüsse identifizieren.
- Machtstrukturen sichtbar machen.

Auf dem Weg zu einer geisteswissenschaftlichen KI-Ethik

Statt XAI

- Kritische Auseinandersetzung.
- Zusammenarbeit zwischen technischer und geisteswissenschaftlicher Expertise.
- Integration (echter) ethischer Reflexion in Forschungsprozesse.
- Berücksichtigung von Arbeit, Macht und historischem Kontext.

Wichtige Ressourcen

- Data Feminism.
- Feministische Care-Ethik.
- CARE-Prinzipien.
- Partizipative und gemeinschaftsorientierte Ansätze.

Ein ethischer Umgang mit LLMs in den Geisteswissenschaften erfordert ein erweitertes ethisches Instrumentarium, das über Erklärbarkeit, Compliance und technische Risikominderung hinausgeht.

Audits zur Bekämpfung von Bias an der Wurzel

Grundproblem

LLMs übernehmen die politischen, ökonomischen und ideologischen Kontexte der Akteure und Institutionen, die ihre Daten und Technologien hervorbringen.

Warum Trainingsdaten wichtig sind

- LLMs werden mit riesigen, intransparenten und oft unkuratierten Datensätzen trainiert.
- Diese Datensätze enthalten diskriminierende, toxische und ausgrenzende Online-Inhalte.
- Das Modellverhalten spiegelt daher die sozialen und politischen Bedingungen seiner Trainingsdaten wider.
- Unbekannte oder nicht offengelegte Trainingsdaten erschweren eine fundierte Kritik.

Ergo

Bias muss auf der Ebene der Trainingsdaten und der Modellinfrastruktur adressiert werden, nicht nur auf der Ebene der sichtbaren Modellausgaben.

Die Grenzen nachgelagerter Filter

Oberflächliche Lösungen

Nachgelagerte Filter können schädliche Ausgaben an der Benutzeroberfläche unterdrücken, verändern jedoch weder das zugrunde liegende Modell noch die in den Daten verankerten Verzerrungen.

Probleme

- Filter können umgangen, abgeschwächt oder entfernt werden.
- Problematische Muster bleiben im Modell erhalten.
- Content-Moderator:innen sind bei ihrer Arbeit belastendem Material ausgesetzt.
- Nutzende tragen unbewusst ausbeuterische Praktiken der KI-Industrie mit.

Analogie

Ähnlich wie das Umlenken diskriminierender Suchergebnisse verlagert das Filtern den Schaden (v.a. in den globalen Süden), statt seine strukturellen Ursachen zu beseitigen.

Datensatz- und Algorithmus-Audits

Warum Audits relevant sind

Feministische und kritische Ansätze betrachten Trainingsdaten als den zentralen Ort ethischer Probleme und fordern eine systematische Prüfung von Datensätzen und Algorithmen.

Funktionen von Audits

- Eingebettete Verzerrungen aufdecken.
- Fehlende oder marginalisierte Perspektiven identifizieren.
- Modellverhalten in unterschiedlichen Anwendungsszenarien testen.
- Aufzeigen, wie Modellausgaben dominante kulturelle Annahmen reproduzieren.

Beispiel

Ein Audit eines Bildgenerierungsmodells mit der Eingabe eines inklusiven Badezimmers offenbarte einen starken Bias gegenüber Menschen mit Behinderungen und hatte keinerlei Vorstellung davon, wie ein inklusives WC aussehen könnte, was zu einer unzureichenden Darstellung barrierefreier Einrichtungen führen würde (und wir verwenden AI ja immer mehr für alles).

Audits geisteswissenschaftlicher Datensätze

Übernommene Datensätze

Geisteswissenschaftler:innen greifen aus praktischen Gründen häufig auf übernommene oder weiterverwendete Datensätze zurück.

Risiken

- Historische Datensätze enthalten frühere Ausschlüsse und Verzerrungen.
- Digitalisierung verstärkt häufig bereits dominante Stimmen.
- Projekte der Digital Humanities können etablierte Kanones reproduzieren.
- Kanonische Figuren wie Goethe oder Shakespeare bleiben oft überrepräsentiert.

Praktischer Nutzen von Audits

Wenn Forschende die verfügbaren Datensätze nicht grundlegend verändern können, sollten sie zumindest sichtbar machen, was diese enthalten, was sie ausschließen und welche historischen Annahmen sie reproduzieren.

Praktische Grenzen von Audits

Wirksam, aber ressourcenintensiv

Datensatz- und Algorithmus-Audits gehören zu den wirksamsten Maßnahmen gegen Bias, erfordern jedoch erhebliche Ressourcen.

Einschränkungen

- Zeit.
- Technische Expertise.
- Fachliche Expertise.
- Finanzierung.
- Institutionelle Unterstützung.

Ethische Audits müssen ausdrücklich geplant, finanziert und institutionell unterstützt werden, statt als freiwillige Zusatzaufgabe behandelt zu werden.

Versteckte Kosten: AI & Umwelt

Ist die Nutzung von LLMs ein Umweltproblem?

Ist die (persönliche/wissenschaftliche) Nutzung von LLMs ein Umweltproblem?

- KI-gestützte Suche ist energieintensiver als herkömmliche Suche.
- Viele Suchmaschinen integrieren inzwischen standardmäßig KI.
- Einige argumentieren, dass die persönliche KI-Nutzung nur vernachlässigbare Umweltauswirkungen hat (Masley 2025).
- Wir brauchen Reporting zu Umweltfolgen, aber auch geeignete Vergleichsmaßstäbe.
- Die CO₂-Reporting sollte standardisiert angewandt werden.




Quellen

<https://www.nytimes.com/2025/09/26/opinion/ai-quartz-mining-hurricane-helene.html>
<https://www.youtube.com/watch?v=OJWcZLx45pw>

Umweltauswirkungen in den Digital Humanities

LLMs und die Umwelt

- Frühes Interesse an Umweltauswirkungen durch die DHd AG Greening DH und das Manifest *DH and the Climate Crisis* (Baillot u. a. 2021).
- Nachhaltigkeit in der Archivierung wird bereits seit 2019 diskutiert (Pendergrass u. a. 2019).
- Seit 2023 starker Anstieg der LLM-Nutzung und des öffentlichen Interesses; wichtige Arbeiten thematisieren Umweltaspekte (z. B. *Stochastic Parrots* = Bender u. a. 2021).
- Die wahrgenommene LLM-Revolution betrifft jedoch vor allem Nutzbarkeit und Wahrnehmung, weniger die Technologie selbst (Narayanan und Kapoor 2024).





Mehr Informationen

<https://dhd-greening.github.io/>

Kritische Perspektiven: Kate Crawford's *Atlas of AI*

KI-Kritik: Erde, Wasser, Energie

- **Kate Crawford:** treibt kritische Perspektiven auf KI voran (*ImageNet Roulette*, *Anatomy of an AI System*, ...).
- **Neuere Arbeit:** Ein Beitrag in der NY Times verweist auf den Bergbau in Spruce Pine (North Carolina, USA) und die Folgen des Hurrikans Helene → zentraler Abbauort für hochreinen Quarz in der KI-Lieferkette.



Wasser und Energie: Schätzungen und Unsicherheit

KI, Wasser und die Herausforderungen der Reporting

- **Hank Green** erklärt die Komplexität des Wasserverbrauchs von KI.
- Mehrere Schätzungen sind plausibel, unterscheiden sich aber erheblich.
- Der Begriff „**guesstimate**“ verdeutlicht die Unsicherheit der Metriken.
- Die Auswirkungen einzelner Anfragen lassen sich wegen vieler verborgener Variablen nur schwer bestimmen – selbst wenn alle erforderlichen Informationen öffentlich verfügbar wären.



Why is Everyone So Wrong About AI Water Use??



Hank Green
2.94M subscribers




Auf YouTube ansehen

https://www.youtube.com/watch?v=H_c6MWk7PQc

Zentrale Punkte

- CO₂-Reporting erhält in einigen LLM-Kontexten zunehmend Aufmerksamkeit.
- Das BLOOM-Modell wurde unter diesem Gesichtspunkt entwickelt (Luccioni, Viguier und Ligozat 2023).
- **DH-Community:** Gemischte oder ausbleibende Reaktion in der Computational Humanities Research (CHR)-Community.
- Ist das Eintreten für CO₂-Reporting in den DH nicht relevant?



Published December 11, 2025 | Version 1

Working paper 

Quantifying the Environmental Footprint of Curating Datasets with LLMs

Lang, Sarah (Contact person)¹  Pitawanik, Wishyut (Researcher)¹  ;
Belouin, Pascal (Researcher)¹  Sevink, Emma (Data curator)²  ;
Olszynko-Gryn, Jesse (Researcher)¹  Freeborn, Alfred (Researcher)¹  ;
Benson, Etienne (Project leader)¹ 

Show affiliations

This study evaluates the environmental trade-offs of using large language models to curate cross-collection oral-history datasets in the *Commoning Oral Histories of Knowledge* (CORAL) project. Manual screening of 2,606 interviews was benchmarked against a workflow that tested four instruction-tuned LLMs and two prompt designs. Environmental impact was approximated using token-based inputs to EcoLogis, although implementing such assessments remains non-trivial. Ultimately, we conclude that the environmental impact of our project's use case could be considered moderate compared to common academic activities such as traveling to conferences. However, such impacts should be monitored closely, as they may very significantly across different research setups and are likely to scale with larger datasets and broader adoption of LLMs in the field. Finally, the paper urges

Mehr Informationen:

Lang, Sarah, Wishyut Pitawanik, Pascal Belouin, Emma Sevink, Jesse Olszynko-Gryn, Alfred Freeborn, and Etienne Benson. "Quantifying the Environmental Footprint of Curating Datasets with LLMs". Zenodo, December 11, 2025. <https://doi.org/10.5281/zenodo.17902822>. (Zenodo DHd AG Greening DH Community)

CO₂-Reporting: Technische und regulatorische Aspekte

Es ist kompliziert...

- Werkzeuge US-amerikanischer Unternehmen sind nicht mit den deutschen Datenschutzvorgaben vereinbar. Der lokale Anbieter GWVG arbeitet offenbar an einer Lösung.
- Unser Beitrag soll praktische Orientierung und abgeleitete Kennzahlen für die lokale Nutzung bieten. Die Methodik basiert (etwas naiv) auf Eingabe-/Ausgabetokens und dem Ort der Berechnung.
- Diese Werte sind nur *guesstimates*, da sie auf unvollständigen und indirekten Kennzahlen beruhen! Vorsicht vor Scheingenauigkeit!



Search records... 

Communities My dashboard

 DH AG Greening DH

Published December 11, 2025 | Version v1

Working paper 

Quantifying the Environmental Footprint of Curating Datasets with LLMs

Lang, Sarah (Contact person)¹  Pitawanik, Wishyut (Researcher)¹ 
Belouin, Pascal (Researcher)¹  Sevink, Emma (Data curator)² 
Olszynko-Gryn, Jesse (Researcher)¹  Freeborn, Alfred (Researcher)¹ 
Benson, Etienne (Project leader)¹ 

Show affiliations

This study evaluates the environmental trade-offs of using large language models to curate cross-collection oral-history datasets in the Commoning Oral Histories of Knowledge (CORAL) project. Manual screening of 2,606 interviews was benchmarked against a unified dataset for evaluation and LLM-based text analysis. Environmental estimates are provided using the...

Quelle

Lang, Sarah, Wishyut Pitawanik, Pascal Belouin, Emma Sevink, Jesse Olszynko-Gryn, Alfred Freeborn, and Etienne Benson. "Quantifying the Environmental Footprint of Curating Datasets with LLMs". Zenodo, December 11, 2025. <https://doi.org/10.5281/zenodo.179028249/62> (Zenodo DHd AG Greening DH Community)

Das CORAL-Projekt: CO₂-Reporting in der Praxis

CORAL

- Projekt *Commoning Oral Histories of Knowledge*.
- Einsatz von LLMs zur Kuratierung thematischer Teilsammlungen.
- Schlüsselwortsuche versagt bei komplexen Umweltbegriffen.
- LLMs dienen der Vorsortierung von Interviews nach Relevanz.
- Human-in-the-loop-Workflow für die abschließende Auswahl und Validierung.
- Vergleich menschlicher Arbeitsleistung mit LLM-Ergebnissen.



[home](#) [about](#) [contact us](#) | [sign up](#) [login](#)

CORAL: Commoning Oral Histories of Knowledge is a digital platform that facilitates research across dispersed oral history collections by indexing their transcripts and metadata. It enables researchers to search across collections held at different institutions, visualize and analyze connections between interviews, and explore themes, places, and people, while acting as a meta-platform that increases the visibility of underused archives and guides users back to the institutions that preserve them. The platform features catalogues of collections relevant to specific themes in the history of science, technology, medicine, and environment.

ComBio

Commoning Biomedicine (ComBio) aims to bring together numerous oral history repositories that can already be found online in a manner that makes them more visible and accessible to historians of biomedicine. These repositories are diverse and range from large institutional archives to small and thematically focused collections.

ComBio currently makes fully searchable a total of **1637** records from **15** collections.

[Search](#) [Statistics](#) [Analytical tools](#)

SEES

The Storying the Earth and Environmental Sciences (SEES) catalogue indexes diverse collections of oral histories of environmental knowledge, making them more discoverable and accessible to historians, practitioners, community members, policymakers, and environmental scientists. The SEES catalogue is under active development and will continue to grow as relevant collections are identified and our community of collaborators expands.

SEES currently makes fully searchable a total of **332** records from **8** collections.

[Search](#) [Statistics](#) [Analytical tools](#)

Zur Plattform

<https://coral.mpiwg-berlin.mpg.de/>

Die mangelnde Nachhaltigkeit von KI

Umweltaspekte

Training und Einsatz großer Sprachmodelle erfordern erhebliche Rechenressourcen; ihr Energiebedarf wird ohne Regulierung voraussichtlich weiter steigen.

Warum das für die Geisteswissenschaften wichtig ist

- LLMs sind für spezialisierte geisteswissenschaftliche Aufgaben oft nicht erforderlich.
- Kleinere Modelle lassen sich häufig leichter finetunen.
- Klassische Machine-Learning-Verfahren können stabiler und effizienter sein (z.B. Transkribus).
- Nur das Notwendige einzusetzen fördert finanzielle und ökologische Verantwortung.

Prinzip

Die Wahl computergestützter Methoden sollte sich am Forschungsbedarf orientieren, nicht an der Verfügbarkeit oder dem Prestige großer KI-Systeme.

Kleinere und nachhaltigere Modelle wählen

Eine nachhaltige Alternative

Für viele geisteswissenschaftliche Anwendungsfälle liefern kleinere und spezialisierte Modelle bessere Ergebnisse als große Foundation-Modelle.

Vorteile

- Geringerer Energieverbrauch.
- Niedrigere Kosten.
- Einfacheres Fine-Tuning.
- Höhere Stabilität.
- Bessere Eignung für eng abgegrenzte, domänenspezifische Aufgaben.

Institutionelle Relevanz

Viele Einrichtungen können die für großskalige KI erforderliche Infrastruktur nicht bereitstellen, wodurch kleinere Modelle praktikabler und gerechter sind.

Der materielle Fußabdruck von KI

Mehr als Energieverbrauch

Die Nachhaltigkeit von KI beschränkt sich nicht nur auf den Stromverbrauch.

Weitere Umweltkosten

- Wasserverbrauch zur Kühlung von Rechenzentren.
- Hardware-Upgrades für großskalige Berechnungen.
- Elektroschrott durch veraltete Infrastruktur.
- Export von Elektroschrott in den Globalen Süden.
- Langfristige Kosten der digitalen Langzeitarchivierung und Datenspeicherung.

Ethisches Dilemma

Die Umweltbelastungen von KI treffen häufig Menschen, die weit von den jenen entfernt sind, welche von der Recheninfrastruktur und den AI-Tools profitieren.

Praktische Maßnahmen

Wir sollten berücksichtigen:

- ob ein LLM überhaupt erforderlich ist,
- ob ein kleineres Modell ausreichen würde,
- den Umfang der Ein- und Ausgabetokens,
- effizientes Prompting und den sparsamen Einsatz von APIs,
- Werkzeuge zur Erfassung der Umweltauswirkungen.

Skalierung ist entscheidend

Die gelegentliche Nutzung durch Einzelpersonen hat möglicherweise nur begrenzte Auswirkungen, großskaliger institutioneller Einsatz kann jedoch erhebliche ökologische und finanzielle Kosten verursachen.

Versteckte Arbeit

Arbeitsverlagerung statt Arbeitsreduktion

Das Versprechen der Automatisierung

LLMs werden häufig als Werkzeuge beworben, die wissenschaftliche Arbeit reduzieren.

In der Praxis

Viele Aufgaben entfallen jedoch nicht, sondern werden verlagert:

- Überprüfung von KI-generierten Inhalten,
- Verifikation von Zitaten,
- Korrektur von Halluzinationen,
- Validierung von Interpretationen,
- Überarbeitung generierter Texte.

Ergebnis

Automatisierung verlagert Arbeit häufig von der Produktion zur Kontrolle und schafft neue Formen kognitiver und redaktioneller Arbeit.

Eine neue Bedrohung

KI-generierte Publikationen tragen zum wachsenden Problem betrügerischer oder qualitativ minderwertiger wissenschaftlicher Veröffentlichungen bei.

Folgen

- Vertrauensverlust in die Wissenschaft.
- Höhere Belastung für Gutachter:innen und Herausgeber:innen.
- Erschwerte Erkennung betrügerischer Einreichungen.
- Zunehmendes „Wettrüsten“ zwischen Verlagen und Paper Mills.

KI und das Publish-or-Perish-System

Beschleunigungseffekte

KI-gestützte Schreibwerkzeuge können Forschungsprozesse unterstützen, zugleich aber auch die Produktion wissenschaftlicher Publikationen beschleunigen.

Mögliche Risiken

- Steigende Produktivitätserwartungen.
- Zunehmender Publikationsdruck.
- Weniger Zeit für Reflexion.
- Weniger Raum für kritische Auseinandersetzung.
- Anreize zugunsten von Quantität statt Qualität.

KI als Verstärker

KI wird bestehende strukturelle Probleme der Wissenschaftskultur eher verstärken als entschärfen.

Der Privilege Hazard

Wir lernen aus Data Feminism

Menschen, die keine strukturelle Diskriminierung erfahren haben, erkennen häufig nur schwer, wie Technologien marginalisierte Gemeinschaften beeinflussen.

Der „Privilege Hazard“

- Ethische Schäden bleiben für nicht direkt Betroffene oft unsichtbar.
- Gute Absichten und ‘gesunder Menschenverstand’ reichen nicht aus (dort leben Vorurteile).
- Ethische Bewertung erfordert Fachwissen und spezifische Kompetenzen.
- Eine ethische KI-Entwicklung erfordert die aktive Einbeziehung betroffener Gemeinschaften und eine Vielfalt von Perspektiven.

Ethics-Washing

Nutzende oder Hersteller können den Eindruck ethischer Compliance vermitteln, ohne sich tatsächlich mit ethischen Herausforderungen auseinanderzusetzen.

Fazit

Wir benötigen konkrete Methoden zur Bewertung ethischer Risiken um Datensätze, Annahmen, Einschränkungen und Unsicherheiten sichtbar und nachvollziehbar machen.

Diagnosewerkzeuge

- Explainable AI (XAI)
- Datensatz-Audits
- Algorithmen-Audits
- Repräsentationsanalysen

Dokumentationswerkzeuge

- Datasheets
- Data Papers
- Model Cards
- Provenienzdokumentation

Fazit: Ethik, Arbeit und wissenschaftliche Integrität

Fazit

Der ethische Umgang mit LLMs ist nicht nur eine technische Frage, sondern auch eine Frage von Arbeit, Transparenz und wissenschaftlicher Integrität.

Drei zentrale Probleme

1. LLMs können irreführende Erklärungen und Halluzinationen erzeugen.
2. Arbeit wird verlagert statt ersetzt.
3. Bestehende wissenschaftliche und technische Infrastrukturen verdecken häufig ethische Probleme.

Fazit

Ein sinnvoller ethischer Umgang erfordert Audits, Dokumentation, kritische Reflexion und institutionelle Unterstützung, statt sich allein auf technische Lösungen oder Compliance-Rahmenwerke zu verlassen.

Literatur

- [1] Anne Baillot u. a. *Digital Humanities and the Climate Crisis: A Manifesto*. <https://dhc-barnard.github.io/dhclimate/>. Online document. 2021.
- [2] Emily M. Bender u. a. „On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?“ In: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. FAccT '21. Virtual Event, Canada: Association for Computing Machinery, 2021, S. 610–623. ISBN: 9781450383097. DOI: [10.1145/3442188.3445922](https://doi.org/10.1145/3442188.3445922). URL: <https://doi.org/10.1145/3442188.3445922>.
- [3] Alexandra Sasha Luccioni, Sylvain Viguier und Anne-Laure Ligozat. „Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model“. In: *Journal of Machine Learning Research* 24 (2023), S. 1–15. URL: <https://www.jmlr.org/papers/volume24/23-0069/23-0069.pdf>.
- [4] Andy Masley. *Why using ChatGPT is not bad for the environment – a cheat sheet*. <https://andymasley.substack.com/p/a-cheat-sheet-for-conversations-about>. Substack blog post. Apr. 2025.
- [5] Arvind Narayanan und Sayash Kapoor. *AI Snake Oil: What Artificial Intelligence Can Do, What It Can't, and How to Tell the Difference*. Princeton, NJ: Princeton University Press, 2024.

- [6] Keith Pendergrass u. a. „**Toward Environmentally Sustainable Digital Preservation**“. In: *The American Archivist* 82.1 (Juni 2019), S. 165–206. DOI: [10.17723/0360-9081-82.1.165](https://doi.org/10.17723/0360-9081-82.1.165). URL: <https://doi.org/10.17723/0360-9081-82.1.165>.
- [7] Grant Sanderson und Justin Sun. **Deep Learning. Chapter 5. Transformers, the Tech Behind LLMs**. Lesson by Grant Sanderson; text adaptation by Justin Sun. 3Blue1Brown. 1. Apr. 2024. URL: <https://www.3blue1brown.com/lessons/gpt/> (besucht am 06.08.2026).
- [8] Grant Sanderson und Justin Sun. **Large Language Models Explained Briefly**. Lesson by Grant Sanderson; text adaptation by Justin Sun. 3Blue1Brown. 20. Nov. 2024. URL: <https://www.3blue1brown.com/lessons/mini-llm/> (besucht am 06.08.2026).